

NO.2 逻辑回归

逻辑回归，虽然名为回归，其实是一个分类模型，而且是线性分类模型，属于判别式模型。这里从二分类为例子，来说明逻辑回归的推导。

对于一个二分类问题， $\{(x_i, t_i), i = 1, \dots, n\}$, 其中 $t_i \in \{C_1, C_2\}$ 。为了实现分类的目的，对于新的 x ，从概率的角度，如果我们知道了两个类别关于 x 的条件概率，那么我们就可以根据这两个概率做出分类的决策。因此我们只要求到其中某一个类别的概率即可（另一个类别的概率等于 1 减去此类别的概率）。于是，我们要求：

$$\begin{aligned} p(C_1|x) &= \frac{p(x|C_1)p(C_1)}{p(x|C_1)p(C_1) + p(x|C_2)p(C_2)} \\ &= \frac{1}{1 + \exp(-a)} = \sigma(a) \end{aligned}$$


其中，

$$a = \ln \frac{p(x|C_1)p(C_1)}{p(x|C_2)p(C_2)}$$

$\sigma(a)$ 是 logistic sigmoid 函数，定义为：

$$\sigma(a) = \frac{1}{1 + \exp(-a)}$$

图形形状为：



可以看到，如果 $a = \ln \frac{p(x|C_1)p(C_1)}{p(x|C_2)p(C_2)} = \ln \frac{p(C_1|x)}{p(C_2|x)} > 0$ ，即 $\frac{p(C_1|x)}{p(C_2|x)} > 1$ ，那么 $\sigma(a) > 0.5$ ，因此我们可以以 0.5 为阈值，如果 $\sigma(a) > 0.5$ ，则判别为类别 C_1 。这样的判别等价于如果 $p(C_1|x) > p(C_2|x)$ ，那么判别类别 C_1 。

一般情况下，我们会对输入向量做一个线性变换，变成特征向量 $w^T x$ 之后，再在完成上訴

步骤。逻辑回归的主要任务就是学习参数 w 。

因此，逻辑回归的形式为

$$p(C_1|x) = y(x) = \sigma(w^T x)$$

注意：对于非线性问题，我们可以对输入向量做一个特征变换，得到特征向量 $\phi(x)$ ，在特征空间上，分类问题变成线性可分的，逻辑回归的形式变为：

$$p(C_1|\phi) = y(\phi) = \sigma(w^T \phi)$$

最大似然法确定参数

在完成最大似然法的过程中，要用到对 logistic sigmoid 函数的导数：

$$\frac{d\sigma(a)}{da} = \sigma(1 - \sigma)$$

对于一个数据集 $\{(x_i, t_i), i = 1, \dots, n\}$, $t_i \in \{0, 1\}$ ，似然函数可以写成

$$p(\mathbf{t}|\mathbf{w}) = \prod_{i=1}^n y_i^{t_i} \{1 - y_i\}^{1-t_i}$$

其中 $\mathbf{t} = (t_1, \dots, t_n)$, $y_i = p(t_i = 1|x_i) = \sigma(w^T x_i)$

通过取似然函数的负对数，定义一个误差函数

$$E(\mathbf{w}) = -\ln p(\mathbf{t}|\mathbf{w}) = -\sum_{i=1}^n \{t_i \ln y_i + (1 - t_i) \ln(1 - y_i)\}$$

两侧关于 w 取误差函数的梯度，得到

$$\nabla E(\mathbf{w}) = \sum_{i=1}^n (y_i - t_i) x_i = \sum_{i=1}^n (\sigma(w^T x_i) - t_i) x_i = X^T (\mathbf{y} - \mathbf{t})$$

X 为设计矩阵。

没有解析解。

由于误差函数是凸函数（二次导大于 0），所以有唯一的最小值，因此采用牛顿-拉夫森迭代法：

$$\mathbf{w}^{\text{new}} = \mathbf{w}^{\text{old}} - H^{-1} \nabla E(\mathbf{w})$$

其中， H 为 Hessian 矩阵，其元素由 $E(\mathbf{w})$ 关于 w 的二阶导数构成。

于是有

$$\mathbf{w}^{\text{new}} = \mathbf{w}^{\text{old}} - (X^T R X)^{-1} X^T (\mathbf{y} - \mathbf{t})$$

其中 R 为对角阵，对角元素为 $R_{nn} = y_n(1 - y_n)$

对于多分类问题，激活函数由 logistic sigmoid 函数变为 softmax 函数

$$p(C_k|x) = y_k(x) = \frac{\exp(w_k^T x)}{\sum_j \exp(w_j^T x)}$$

其余步骤类似二分类情形。